


APRENDIZAJE DE MÁQUINA

Preprocesamiento





Preprocesamiento

Introducción, Data cleaning: Valores faltantes y duplicados, **Data**

transformation: Codificación de los datos Escalamiento de los datos

Normalización de los datos, **Data reduction:** Selección de características


Extracción de característica, **Conclusiones**

#1. Introducción

Datoos!!! Muchos datos!!

- Recurso más valioso hoy en el mundo actual.
- Según el Foro Económico Mundial, para el 2025 estaremos generando alrededor de **463 exabytes de datos a nivel mundial por día.**
- Pero:

¿Todos estos **datos** son lo **suficientemente adecuados** para ser utilizados por algoritmos de aprendizaje automático?



Saturdays.AI

Hablando de datos pensamos ...

- Grandes conjuntos de datos con una gran cantidad de filas y columnas.
- No siempre es el caso: los datos pueden estar en muchas formas diferentes: tablas estructuradas, imágenes, archivos de audio, videos, etc.
- Las máquinas no entienden el texto libre, las imágenes o los datos de video tal como están, entienden los 1 y 0.

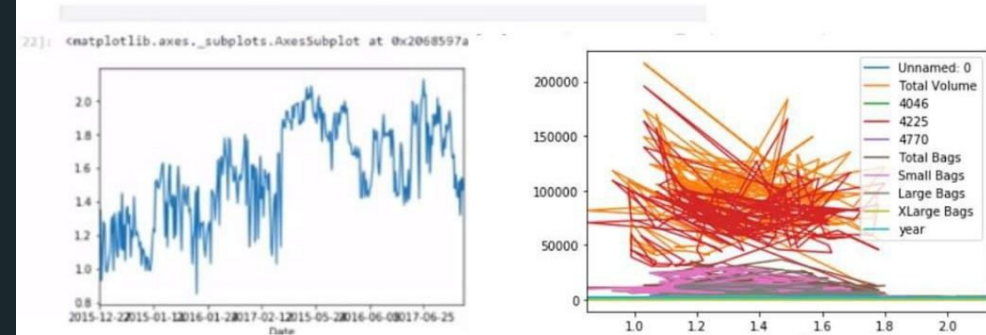
Item	Category	Size	Unit	Starting Qty	Starting Value	Wk 1 Qty	Wk 1 Cost	Wk 2 Qty	Wk 2 Cost	Wk 3 Qty	Wk 3 Cost	Wk 4 Qty	Wk 4 Cost
492229 TURKEY SLICED 5 OZ	Ben E Keith 2 - FROZEN FOOD	0	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
662371 DRESSING CAESAR CREAMY	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
779243 MARGARINE LIQUID OLEO	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
815396 LEO PLUS SOUPLE CLEAR	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
860055 LEO PLUS 180L SLOTTED	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
860060 CUP FOAM 180Z 1818	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
774704 ZAPRUKA	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
64009 Shredded Prepared	Ben E Keith 4 - GROCERY	512 Fl oz	0	0.00	\$	1.00	\$ 3.75	0.00	\$	0.00	\$	0.00	\$
790100 CHEESE PARMESAN SHRED	Ben E Keith 24 - GROCERY	0	0	0.00	\$	0.00	\$	0.00	\$	1.00	\$ 13.27	0.00	\$
250025 EGG FRESH SHELL MED USDA AA	Ben E Keith 1 - PRODUCE	0	0	0.00	\$	1.00	\$ 15.89	0.00	\$	0.00	\$	0.00	\$
686034 UNSEASONED APPLE CIDER VINEGAR	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	1.00	\$ 17.77	0.00	\$	0.00	\$
29078 LIME 12 CT	Ben E Keith 1 - PRODUCE	12 CT	0	0.00	\$	2.00	\$ 8.99	0.00	\$	0.00	\$	0.00	\$
650547 TOMATO DICED W/GREEN CHILES	Ben E Keith 4 - GROCERY	0	0	0.00	\$	1.00	\$ 18.88	0.00	\$	0.00	\$	0.00	\$
286500 Ice Cream Vanilla Cr 3 Gal	Ben E Keith 5 - DAIRY	384 Fl oz	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
650474 BUTTERUP NANCY 3/4 SOLIDS	Ben E Keith 4 - GROCERY	0	0	0.00	\$	1.00	\$ 20.49	0.00	\$	0.00	\$	0.00	\$
140005 MUSHROOM WHITE SMALL BUTTON	Ben E Keith 1 - PRODUCE	0	0	0.00	\$	1.00	\$ 20.98	0.00	\$	0.00	\$	0.00	\$
77131 CROUTON SEASONED HOMESTYLE	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	1.00	\$ 22.30	0.00	\$	0.00	\$
660409 SAUCE LOUISIANA RED HOT	Ben E Keith 4 - GROCERY	0	0	0.00	\$	1.00	\$ 13.24	0.00	\$	1.00	\$ 13.24	0.00	\$
150015 Onion Green Medium W/Root	Ben E Keith 1 - PRODUCE	32 oz	0	0.00	\$	1.00	\$ 8.79	1.00	\$ 8.79	0.00	\$	0.00	\$
780009 SUGAR BROWN LIGHT IN BAGS	Ben E Keith 4 - GROCERY	0	0	0.00	\$	0.00	\$	1.00	\$ 27.69	0.00	\$	0.00	\$
155030 Onion Yellow Jumbo	Ben E Keith 1 - PRODUCE	800 oz	0	0.00	\$	0.00	\$	1.00	\$ 13.99	0.00	\$	0.00	\$
774173 Pepper Red Crushed	Ben E Keith 4 - GROCERY	32 oz	0	0.00	\$	0.00	\$	0.00	\$	0.00	\$	0.00	\$
920919 TUMBLER 20 OZ AMBER	Ben E Keith 8 - EQUIP & SUPPLY	0	0	0.00	\$	0.00	\$	1.00	\$ 29.99	0.00	\$	0.00	\$



Tenemos un problema

- Los datos del mundo real a menudo son:
 - incompletos,
 - inconsistentes,
 - contienen muchos errores.

me everytime:



Expectation

Reality

La calidad de los datos afecta directamente la capacidad de nuestro modelo para aprender.

Y una necesidad

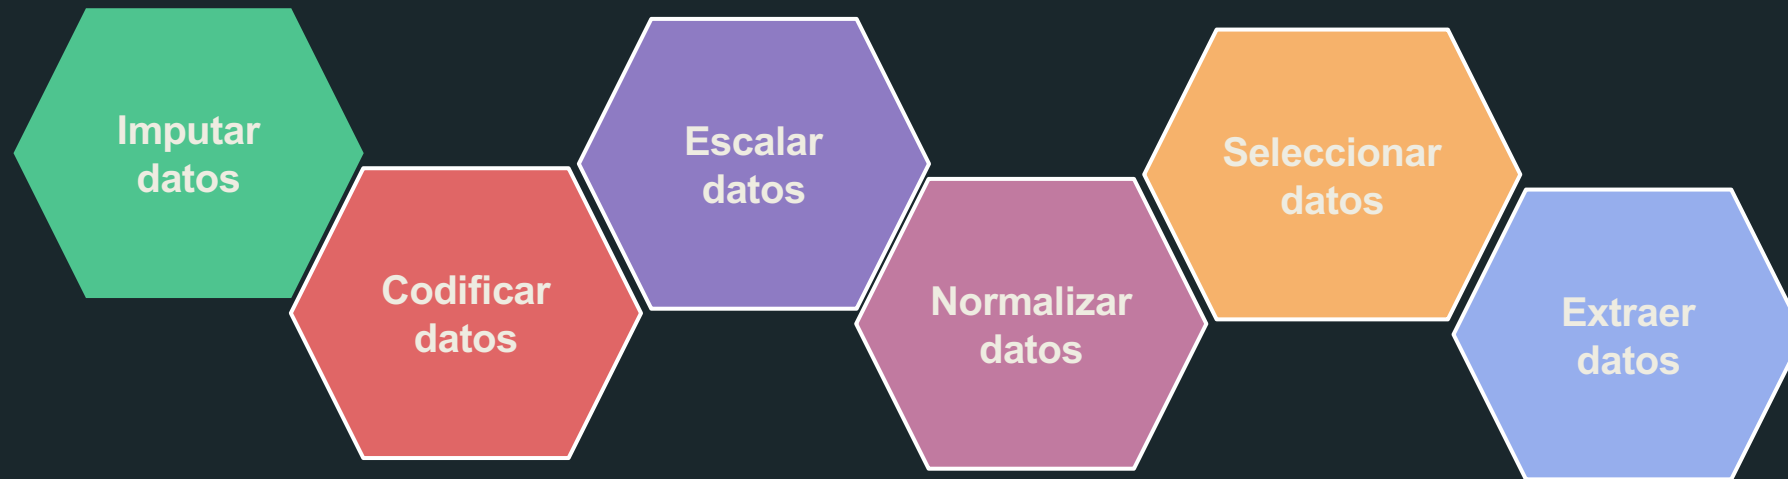
- Contar con datos que sean
 - completos,
 - precisos,
 - válidos



Las características universalmente reconocidas de los datos de buena calidad, que incluyen: accesibilidad, exactitud, exhaustividad, consistencia (o coherencia), definición, vigencia, institucional e interpretabilidad (Teslow, 2016), granularidad, precisión, relevancia, entorno

Data preprocessing

Es el proceso de **aplicar transformaciones a los datos** para llevarlos a un estado que la máquina pueda **analizarlos fácilmente**.



Paso muuuy importante en todo proceso de Machine Learning!!!

Su objetivo es **disponer de datos de calidad** previo al modelado utilizando algoritmos.

Regresión

Clasificación

Datos

Pre-processing

Modelo ML


Salida esperada
/ Predicción

Deben de
tener
relación
directa

?




?



Data preprocessing



Alrededor del **60%** del **tiempo** de los científicos de datos es empleado aquí, **preparando los datos para el modelado.**



Fuente: Forbes (2016).

Paso que requiere mucho tiempo!!!

Definiciones

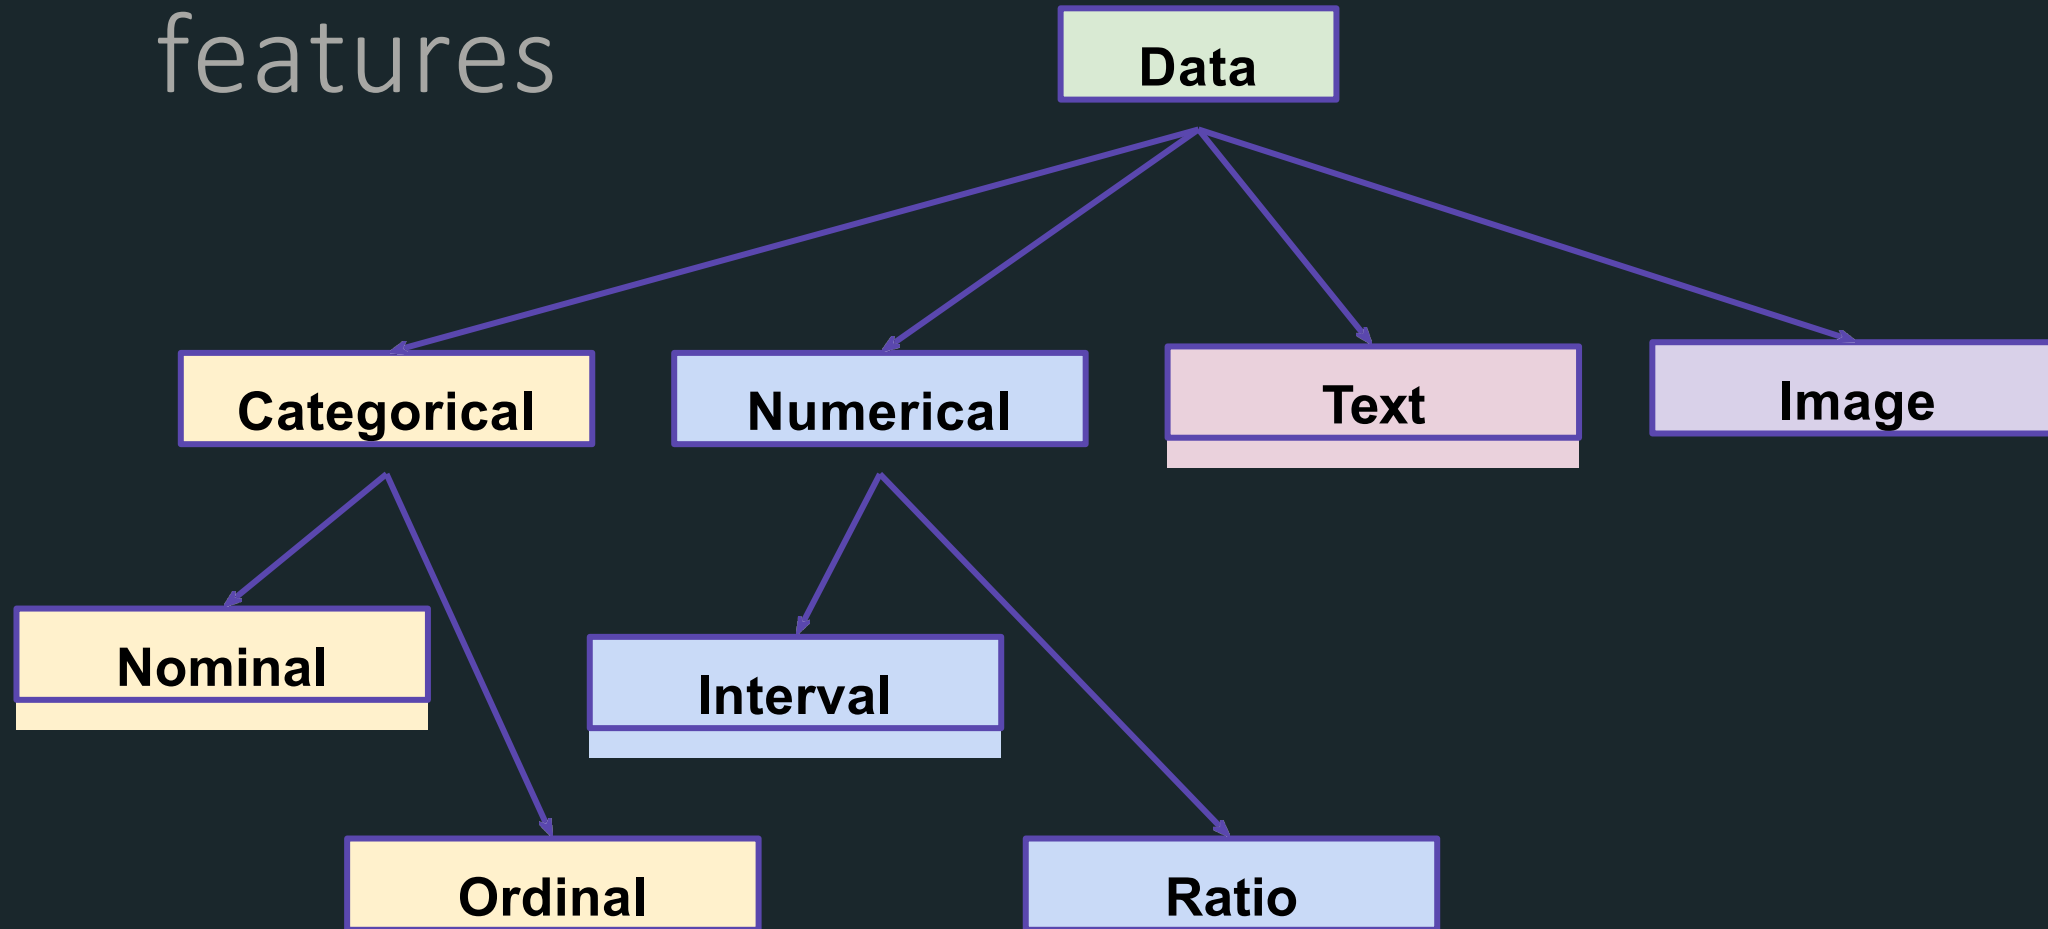
Dataset:

- Colección de datos.
 - **Ejemplos:** registros de interacciones, eventos, observaciones.
- Descritos mediante una serie de características o features.
 - **Ejemplos:** la masa de un objeto físico o el momento en que ocurrió un evento, etc.

Feature vector

← Features →					Label
Position	Experience	Skill	Country	City	Salary (\$)
Developer	0	1	USA	New York	103100
Developer	1	1	USA	New York	104900
Developer	2	1	USA	New York	106800
Developer	3	1	USA	New York	108700
Developer	4	1	USA	New York	110400
Developer	5	1	USA	New York	112300
Developer	6	1	USA	New York	114200
Developer	7	1	USA	New York	116100
Developer	8	1	USA	New York	117800
Developer	9	1	USA	New York	119700
Developer	10	1	USA	New York	121600

Definiciones: Tipos de features



Tipos de features :

Categorical

- Características cuyos valores se toman de un **conjunto definido de valores**.
 - Ejemplos?.... En el chat :D

Nominal

- Variables categóricas **sin un orden implícito**.
- **Ejemplo:** Los colores de un carro: negro, morado, rosa.

Ordinal

- Variables categóricas **con un orden natural implícito**.
- **Ejemplo:** Los tamaños de la ropa: chico, mediano, grande.

Tipos de features :

Numerical

- Características representadas por **números cuyos valores son continuos o discretos.**
 - Ejemplos?.... En el chat :D


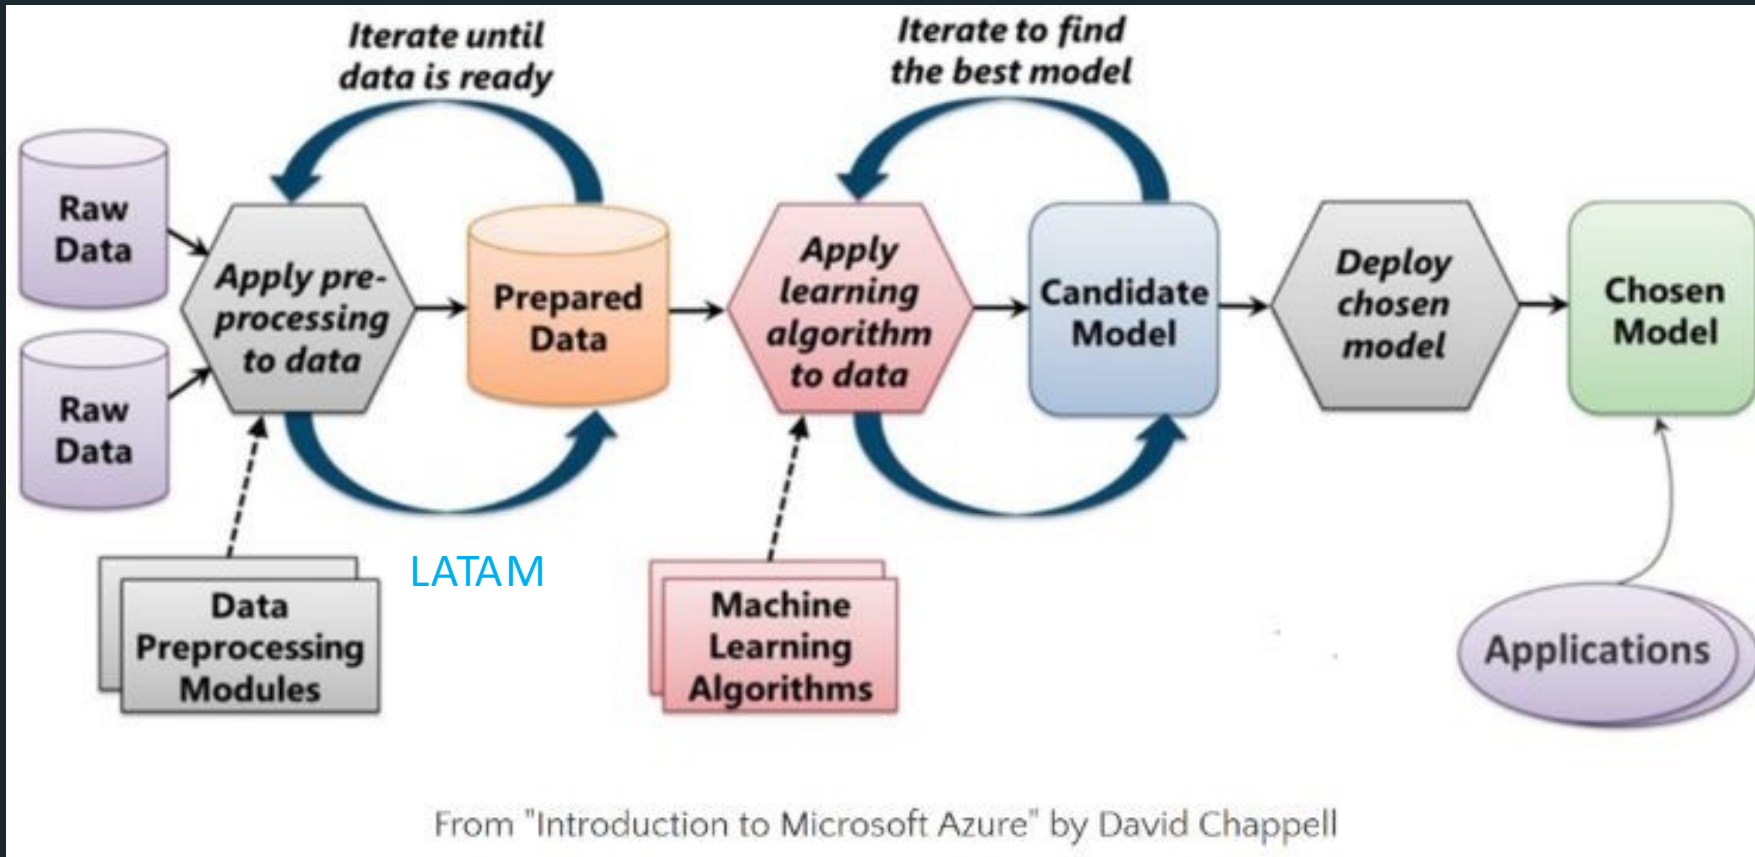
Interval

- Con una unidad de medida definida.
- Representa valores como 0 y menores que 0.
- **Ejemplo:** temperatura en Celsius

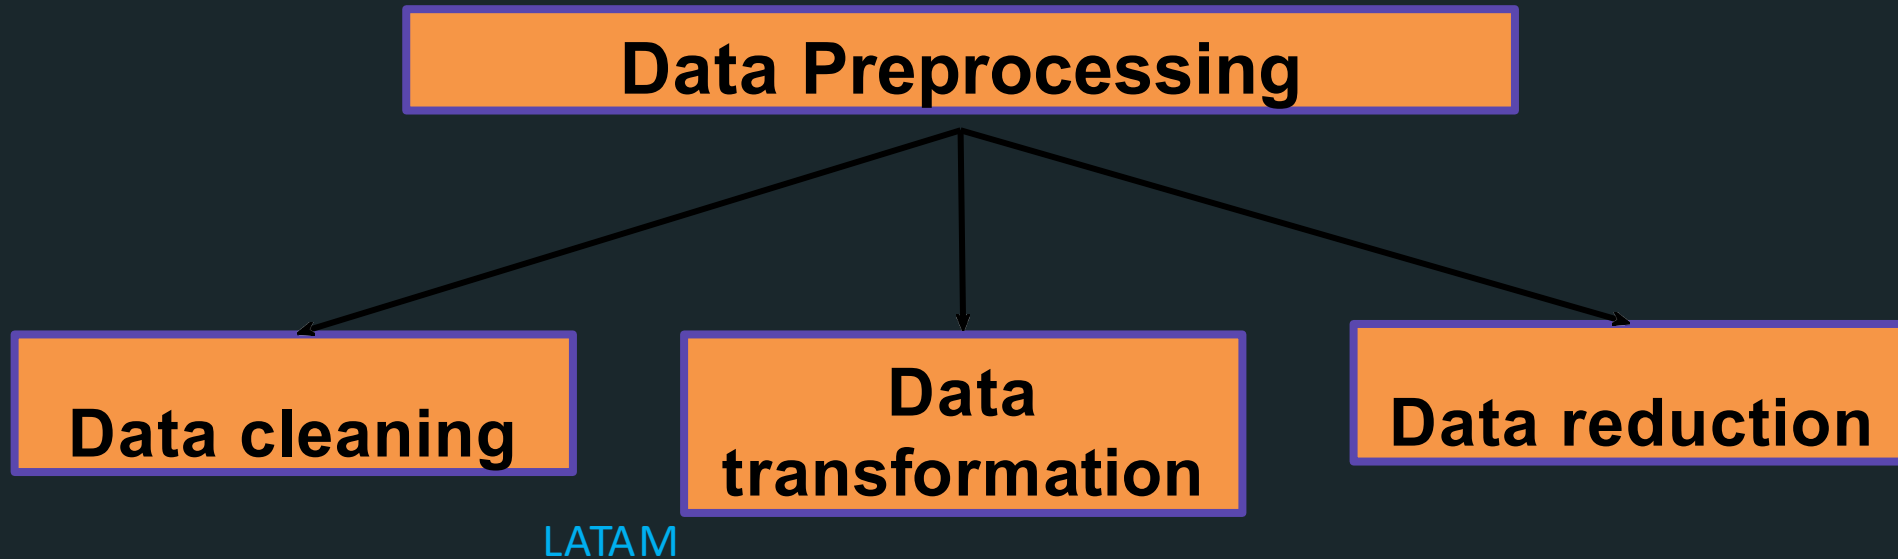
Ratio

- Con una unidad de medida definida.
- Representa valores de 0 y mayores a 0.
- **Ejemplo:** estatura y peso.

Metodología de Ciencia de Datos.



Data Preprocessing





CONCLUSIONES!!!